

Introduction aux Processus Stochastiques

Méthodes de Monte Carlo par chaînes de Markov pour la détection de motifs en bioinformatique

Profs.: Céline ESSER et Pierre GEURTS

Année académique 2025-2026

Le travail est à réaliser par groupe de **deux étudiants maximum**. Le rapport et le code source sont à remettre via Gradescope pour le **vendredi 8 mai 2025 à 23h59**. Une défense orale individuelle sera organisée lors de la dernière semaine de cours.

Contexte général et objectifs

L'objectif général du projet est de développer un algorithme permettant de résoudre le problème de détection de motifs dans des séquences d'ADN. Pour construire ce système, on se basera sur la méthode de Monte Carlo par chaînes de Markov (MCMC pour *Markov chain Monte Carlo* en anglais).

Le projet est divisé en deux parties. La première partie du projet a pour but de vous familiariser avec les chaînes de Markov et la méthode MCMC particulière qui sera utilisée. La deuxième partie, qui constitue le cœur du projet, vise à mettre en œuvre concrètement la méthode MCMC pour résoudre le problème de détection de motifs.

1 Première partie : chaînes de Markov et échantillonnage de Gibbs

La première partie du projet permet de se familiariser avec les chaînes de Markov pour la modélisation de séquences discrètes et de comprendre comment l'échantillonnage de Gibbs fonctionne en l'appliquant sur un problème illustratif simple.

Méthode MCMC et échantillonnage de Gibbs

Soit Y une variable aléatoire prenant ses valeurs dans un espace $\mathcal{Y}$ et de loi $p(Y)$. On souhaite générer des échantillons suivant cette distribution. L'idée générale des méthodes MCMC est de construire une chaîne de Markov ergodique dont la distribution invariante est égale à $p(Y)$. Une réalisation de cette chaîne de Markov fournit alors des échantillons de la distribution cible $p(Y)$.

Il existe plusieurs méthodes MCMC pour construire une chaîne de Markov de distribution invariante $p(Y)$, dont l'algorithme de Metropolis-Hasting vu au cours. Dans ce projet,

on utilisera l'algorithme de Gibbs (voir l'algorithme 1). Cette méthode est utile lorsque la variable aléatoire Y peut se décomposer en une série de N variables aléatoires $Y = (Y_1, \dots, Y_N)$ (prenant leurs valeurs dans des espaces $\mathcal{Y}_i$ potentiellement distincts) et qu'il est aisé d'échantillonner à partir des distributions conditionnelles $p(Y_i | Y_1, \dots, Y_{i-1}, Y_{i+1}, \dots, Y_N)$. L'idée de l'algorithme est de modifier à chaque itération une variable Y_i choisie au hasard en tirant sa nouvelle valeur selon la distribution conditionnelle de Y_i .

Plutôt que de tirer une variable aléatoirement à chaque itération, une variante de l'algorithme, dite à *balayage systématique*, consiste à choisir un ordre arbitraire entre les variables et à les parcourir chacune à leur tour de manière cyclique, toujours dans cet ordre, lors des itérations. Par rapport à l'algorithme 1, cette variante remplace le tirage $i \sim U\{1, \dots, N\}$ par l'instruction $i = t \bmod N + 1$. Les deux algorithmes ont des propriétés théoriques similaires. L'algorithme 1 étant plus facile à analyser, c'est celui-ci que nous utiliserons dans la première partie du travail. La version à balayage systématique, qui est plus populaire, pourra cependant être utilisée dans la deuxième partie du travail si vous le souhaitez.

Algorithm 1 Échantillonnage de Gibbs.

```

Pick a starting value  $y^{(0)} = (y_1^{(0)}, \dots, y_N^{(0)})$ .
t = 0
while convergence not reached do
     $y^{(t+1)} = y^{(t)}$ 
     $i \sim U\{1, \dots, N\}$ 
     $y_i^{(t+1)} \sim p(Y_i | Y_1 = y_1^{(t)}, \dots, Y_{i-1} = y_{i-1}^{(t)}, Y_{i+1} = y_{i+1}^{(t)}, \dots, Y_N = y_N^{(t)})$ 
     $t = t + 1$ 
end while

```

1.1 Chaînes de Markov

L'objectif des questions ci-dessous est de vous faire réfléchir à l'utilisation de chaînes de Markov pour modéliser des séquences discrètes (questions 1 et 5) et de vérifier les propriétés théoriques de processus ergodiques (questions 2, 3, 4).

Fichiers fournis : `sequences_1.1.txt`, contenant trois séquences d'ADN, c'est-à-dire définies sur un alphabet de 4 lettres $\{A, C, G, T\}$ (voir la section 2.1 pour plus de détails).

Questions :

- Utilisez la méthode du maximum de vraisemblance pour construire la matrice de transition P avec $[P]_{i,j} = \mathbb{P}(X_{t+1} = j | X_t = i)$ (où les états A, C, G, T sont numérotés respectivement 1, 2, 3, 4) d'une chaîne de Markov modélisant la séquence `seq1` fournie. Représentez le diagramme d'états de la chaîne correspondante.
- Sur base de la matrice P estimée au point précédent, calculez les quantités suivantes pour des valeurs de t croissantes :
 - $\mathbb{P}(X_t = i)$ en supposant que la première lettre est choisie au hasard, i.e. la lettre initiale est tirée dans une loi uniforme discrète.
 - $\mathbb{P}(X_t = i)$ en supposant que la première lettre est toujours C ,
 - P^t , c'est-à-dire la t -ième puissance de la matrice de transition.

Représentez l'évolution des deux premières grandeurs sur un graphe. Discutez et expliquez les résultats obtenus sur base de la théorie.

3. En déduire la distribution stationnaire¹ π_∞ de la chaîne de Markov définie par $[\pi_\infty]_j = \lim_{t \rightarrow \infty} \mathbb{P}(X_t = j)$.
4. Générez une réalisation aléatoire de longueur T de la chaîne de Markov en démarant d'une lettre choisie arbitrairement. Calculez pour chaque lettre le nombre de fois qu'elle apparaît dans la réalisation divisé par la longueur de la réalisation. Observez l'évolution de ces valeurs pour chaque lettre lorsque T croît. Que concluez-vous de cette expérience ? Reliez ce résultat à la théorie.
5. Calculez et comparez les fréquences d'apparition des lettres A, C, G, T dans les trois séquences fournies. Calculez ensuite les probabilités que les trois séquences aient été générées par la chaîne de Markov estimée sur base de la première. Que pouvez-vous conclure de cette expériences ?

1.2 Échantillonnage de Gibbs

L'objectif des questions ci-dessous est de vous faire étudier les propriétés théoriques de l'algorithme et ensuite de l'appliquer à un problème d'échantillonnage simple pour vérifier ces propriétés.

Questions :

1. Soit la chaîne de Markov définie par l'algorithme de Gibbs. Montrez que la distribution $p(Y)$ satisfait la condition de balance spécifique relative à la matrice de transition de cette chaîne (voir le Lemme 3.6.6, page 67, du cours). Quelles autres conditions la chaîne doit-elle respecter pour que l'algorithme fonctionne ?
2. Soit deux variables Y_1 et Y_2 prenant leurs valeurs dans $\{1, 2, 3, 4\}$.
 - (a) Choisissez une distribution conjointe sur ces deux variables, sous la forme d'une matrice $Q_Y \in \mathbb{R}^{4 \times 4}$ telle que $[Q_Y]_{i,j} = \mathbb{P}(Y_1 = i, Y_2 = j)$, de sorte à ce que l'algorithme 1 puisse être utilisé pour échantillonner selon cette distribution. Justifiez votre choix par rapport aux conditions données au point 1.
 - (b) Générez une réalisation suffisamment longue de la chaîne correspondant à l'algorithme 1. Comparez dans un graphe les fréquences d'apparition de chaque état (défini par une paire de valeurs pour Y_1 et Y_2) dans cette réalisation avec les valeurs de la matrice Q_Y .
 - (c) Répétez l'expérience du point précédent en alternant un échantillonnage de Y_1 puis de Y_2 , plutôt qu'en choisissant une variable aléatoirement à chaque itération. Obtenez-vous les mêmes résultats ?

2 Deuxième partie : détection de motifs dans des séquences d'ADN

L'objectif de cette seconde partie est de développer un algorithme pour détecter un motif commun à plusieurs séquences d'ADN. Ce type d'algorithme est un des outils permettant de

1. On utilisera ici stationnaire et invariante de manière interchangeable.

détecter si un ensemble de gènes sont régulés par le même facteur de transcription et donc partagent une même fonction au sein d'un organisme. De manière simplifiée, un gène est une région de l'ADN qui sera transcrite en ARN messager et ensuite traduit en protéine, ces dernières étant les acteurs essentiels du fonctionnement d'un organisme vivant. Les facteurs de transcription sont des protéines particulières qui vont se coller (souvent en groupe) dans la région en amont du gène sur l'ADN (appelée la région promotrice du gène) et qui vont ainsi activer ou inhiber la transcription de ce gène et donc affecter la quantité de la protéine sous-jacente présente dans la cellule. Le fait qu'un facteur de transcription puisse se coller dans une région promotrice dépend de la structure de la protéine correspondante et de l'occurrence de certains motifs particuliers sur l'ADN. Si un groupe de gènes a été détecté comme étant particulièrement actif ou inhibé dans un phénomène particulier (cellule malade, type cellulaire particulier, étape donnée du développement de l'organisme, etc.), la détection d'un motif dans la région promotrice de ces gènes permet aux biologistes d'identifier les facteurs de transcription potentiellement impliqués dans ce phénomène.

Vu l'importance de la question pour les biologistes, le problème de détection de motifs a fait l'objet de nombreuses recherches et il existe beaucoup d'algorithmes dans la littérature [1]. On s'intéressera ici plus particulièrement à l'approche probabiliste du problème qui met en oeuvre généralement l'échantillonnage de Gibbs. Cette approche a été proposée à la fin des années 90 et étudiée au début des années 2000 et elle fait maintenant partie des méthodes classiques de la littérature. Les idées développées ci-dessous sont basées sur les références suivantes [2, 3, 5, 4] sur le sujet. Vous êtes libres évidemment au cours du projet de consulter ces sources ou d'autres. Tout document consulté devra évidemment être cité de manière appropriée dans votre rapport.

La section 2.1 décrit les grandes idées de l'approche qu'on vous propose d'étudier et d'implémenter. Cette seconde partie du projet est plus libre que la première mais la section 2.2 établit néanmoins un plan de travail, en quatre étapes, pour atteindre l'objectif visé et donne des indications sur le contenu attendu du rapport.

2.1 Formulation du problème

Notations et contexte. Une séquence d'ADN² consiste en une succession de nucléotides pouvant chacun avoir l'une des 4 valeurs A , C , G ou T .³ Dans la suite, on indicera ces valeurs de 1 à 4 dans l'ordre alphabétique A , C , G , T .

On supposera disposer d'un ensemble noté $\mathcal{S} = \{S_1, \dots, S_N\}$ de N séquences de nucléotides de longueurs potentiellement différentes. Ces séquences pourront correspondre par exemple aux régions promotrices d'un ensemble de gènes. On notera $|S_k|$ la longueur de la séquence S_k . La longueur du motif sera supposée connue et notée W . Chaque séquence S_k sera supposée contenir une et une seule occurrence du motif (on supposera que $|S_k| \geq W$ pour tout k). On notera :

- A_k , la variable aléatoire représentant la position du premier nucléotide du motif dans la séquence S_k (avec $A_k \in \{1, \dots, |S_k| - W + 1\}$),
- $\mathcal{A} = (A_1, \dots, A_N)$ les positions des motifs dans toutes les séquences de $\mathcal{S}$,
- $\mathcal{A}_{-k} = (A_1, \dots, A_{k-1}, A_{k+1}, \dots, A_N)$, les positions des motifs dans toutes les séquences sauf A_k .

2. Acide désoxyribonucléique.

3. A pour Adénine, C pour Cytosine, G pour Guanine, T pour Thymine.

Modèles probabilistes. Deux modèles probabilistes de séquences seront considérés, un modèle pour le motif lui-même, dont les paramètres seront notés collectivement Θ , et un modèle pour les séquences en dehors du motif, dont les paramètres seront notés Φ .

Pour ce qui est du motif, on supposera que le nucléotide à la position j ($\forall j = 1, \dots, W$) est tiré d'une distribution multinomiale de paramètres $\theta_j = (\theta_{1,j}, \dots, \theta_{4,j})^\top$. Le modèle comporte donc $4W$ paramètres collectés dans la matrice $\Theta = (\theta_1, \dots, \theta_W) \in \mathbb{R}^{4 \times W}$. Cette modélisation probabiliste permet une certaine souplesse dans la définition d'un motif, dont les nucléotides à certaines positions pourraient être non définis (dans le cas où la distribution multinomiale serait presque uniforme).

Pour le modèle des séquences hors motif, on envisagera deux modèles possible. Le premier supposera que les nucléotides sont tous tirés indépendamment de la même distribution multinomiale définie par 4 paramètres $\Phi = (\phi_1, \phi_2, \phi_3, \phi_4)$. Le second supposera que les séquences hors motif sont générées par une chaîne de Markov $CM(u_\phi, P_\phi)$, avec comme paramètres $\Phi = (u_\phi, P_\phi)$ la distribution initiale de la chaîne $u_\phi \in \mathbb{R}^4$ et sa matrice de transition $P_\phi \in \mathbb{R}^{4 \times 4}$. L'utilisation d'une chaîne de Markov permet de prendre en compte des dépendances spatiales entre nucléotides et améliore généralement la détection de motifs [4].

Étant donné ces modèles, on suppose que chaque séquence S_k a été générée de la manière suivante :

- Une position a_k pour le motif a été tirée au hasard uniformément dans $\{1, \dots, |S_k| - W + 1\}$.
- La séquence entre les positions 1 et $a_k - 1$ est générée selon le modèle Φ .
- La séquence entre les positions a_k et $a_k + W - 1$ est générée selon le modèle Θ .
- La séquence entre les positions $a_k + W$ et $|S_k|$ est générée selon le modèle Φ .⁴

Détection de motif. Étant donné les hypothèses et notations précédentes, le problème de détection de motifs revient à estimer à partir de $\mathcal{S}$ l'ensemble $\mathcal{A}$ des positions des motifs dans les séquences et les paramètres du modèle de motif Θ . Les paramètres Φ interviennent dans le modèle mais leur estimation n'est pas un objectif en soi. Dans ce projet, on supposera que ces paramètres sont fixés a priori. Ils pourront être estimés (au maximum de vraisemblance par exemple) une fois pour toute à partir de séquences d'ADN quelconques représentatives de celles dans l'ensemble $\mathcal{S}$. Si W est petit par rapport aux longueurs $|S_k|$, on peut également les estimer à partir des séquences de $\mathcal{S}$ directement, l'impact des parties de séquences correspondant au motif pouvant être négligé.

Dans ce projet, on abordera ce problème d'estimation comme un problème d'inférence bayésienne en cherchant à calculer la distribution *a posteriori* des paramètres inconnus du modèle, c'est-à-dire :

$$p(\Theta, \mathcal{A} | \mathcal{S}, \Phi).$$

Le calcul de cette distribution étant complexe, on utilisera l'échantillonnage de Gibbs pour obtenir des échantillons de cette distribution. Ces échantillons pourront être ensuite utilisés pour obtenir une estimation des positions $\mathcal{A}$ et des paramètres Φ (par exemple, en déterminant les paramètres les plus probables parmi ceux échantillonnés).

4. Dans le cas où Φ est une chaîne de Markov, on pourra supposer que le nucléotide à la position 1 est tiré de la distribution initiale (si $a_k \neq 1$) et que celui à la position $a_k + W$ est tiré à partir de la matrice de transition conditionnellement à celui à la position $a_k + W - 1$.

2.2 Plan de travail

Sont décrites ci-dessous les grandes étapes du travail par lesquelles nous vous suggérons de passer, avec quelques conseils sur la manière d’aborder chacune de ces étapes.

2.2.1 Dérivations mathématiques

La première étape consiste à dériver les distributions conditionnelles nécessaires à l’algorithme de Gibbs. Vous aurez besoin de deux distributions : $p(\Theta|\mathcal{A}, \mathcal{S}, \Phi)$, qui permettra d’échantillonner des nouveaux paramètres Θ en supposant les positions $\mathcal{A}$ connues et $p(A_k|\mathcal{A}_{-k}, \Theta, \mathcal{S}, \Phi)$, pour $k = 1, \dots, N$, qui permettra d’échantillonner une nouvelle position A_k en supposant les autres positions et le modèle Θ connus.

Pour arriver à formuler ces distributions, vous pouvez procéder comme suit :

- Calculez d’abord $p(S, A|\Theta, \Phi)$ en vous basant sur le modèle de génération de séquences décrit plus haut.
- Utilisez le théorème de Bayes pour calculer $p(\Theta|\mathcal{A}, \mathcal{S}, \Phi)$. Vous aurez besoin pour cela de définir la distribution *a priori* $p(\Theta)$. Les paramètres Θ étant les paramètres de différentes distributions multinomiales (une par position dans le motif), la distribution naturelle pour ça est la distribution de Dirichlet qui est un “conjugate prior” pour la distribution multinomiale. Un document fourni sur Ecampus reprend quelques propriétés de la distribution de Dirichlet qui vous seront utiles pour ce développement.
- Utilisez à nouveau le théorème de Bayes pour exprimer $p(A_k|\mathcal{A}_{-k}, \Theta, \mathcal{S}, \Phi)$ en fonction de $p(S, A|\Theta, \Phi)$.
- Expliquez finalement comment échantillonner des deux distributions obtenues.

Nous vous conseillons de faire d’abord le développement dans le cas où le modèle Φ est une multinomiale par simplicité et de discuter ensuite de comment la formule finale est modifiée dans le cas d’une chaîne de Markov.

2.2.2 Implémentation

Une fois les formules dérivées, vous pouvez implémenter concrètement l’algorithme de recherche de motifs. Cette implémentation peut suivre l’algorithme 1, en utilisant un balayage systématique ou pas.

Une limitation de l’approche cependant, connue dans la littérature, est qu’elle peut se retrouver coincée dans un optimum local correspondant à un décalage constant de toutes les positions par rapport à l’optimum global. En effet, si A^* est le vecteur contenant les positions réelles de début de motifs, alors $A = A^* + \delta$, où δ est petit, est un optimum local, dont l’algorithme de Gibbs, qui ne modifie qu’une position à la fois, aura du mal à s’échapper. Une manière d’éviter ce problème est de vérifier périodiquement si un petit décalage δ de toutes les positions ne permettrait pas d’augmenter $p(\Phi, A|S, \Phi)$ (où Φ devra être ré-échantillonné en fonction des A modifiés). Vous pouvez implémenter cette idée en acceptant ou non le décalage comme cela est fait dans l’algorithme de Metropolis-Hasting.

Dans le rapport, on vous demande de décrire les spécificités de votre implémentation, éventuellement en donnant un pseudo-code de l’algorithme. Expliquez comment vous avez estimé Φ . Précisez quelles valeurs estimées $\hat{\mathcal{A}}$ et $\hat{\Theta}$ sont renvoyées par votre algorithme et justifier votre choix. Vous pouvez renvoyer la paire $(\mathcal{A}, \Theta)$ la plus probable échantillonnée lors des itérations de l’algorithme mais ce n’est pas la seule possibilité.

2.2.3 Expérimentations

Une fois l'algorithme implémenté, il vous est demandé de réaliser des expériences pour étudier son fonctionnement. Vous pouvez utiliser pour cela des séquences générées par vos soins selon le modèle décrit plus haut, ainsi que différents jeux de séquences fournis sur Ecampus.

Critères de performance. Plusieurs critères peuvent être utilisés pour évaluer la qualité des prédictions fournies par votre algorithme [5]. Le premier est la vraisemblance des paramètres estimés, c'est-à-dire $p(S|A, \Theta, \Phi)$. D'un point de vue numérique, il peut être bénéfique de calculer le logarithme de cette vraisemblance (la log-vraisemblance). Au niveau d'un motif, ce dernier est d'autant plus intéressant qu'il correspond à une séquence bien déterminée de nucléotides. On dira alors qu'il est conservé (sa nature ne change pas d'une séquence à l'autre). Une manière de mesurer la conservation d'un motif est le score de consensus suivant :

$$Score_C(\Theta) = 2 - \frac{1}{W} \sum_{i=1}^4 \sum_{j=1}^W \theta_{i,j} \log_2(\theta_{i,j}).$$

Ce score sera égal à 2 dans le cas où un seul nucléotide est possible à chaque position et sera égal à 0 si chaque nucléotide a la même probabilité d'apparaître à chaque position. Une manière de visualiser une matrice Θ est la représentation Logo⁵ que vous pouvez également utiliser.

Lorsque les positions des motifs sont connues, il est intéressant aussi de mesurer à quel point les positions prédites recouvrent les positions réelles des motifs. On peut mesurer pour quantifier cela la moyenne sur toutes les séquences de l'index de Jaccard (AJI, pour "Average Jaccard Index"), ce dernier mesurant le rapport entre l'union et l'intersection des positions prédites et réelles des motifs. Par exemple, soit [2,10], les début et fin du vrai motif et [4, 14], les début et fin du motif prédit. L'indice de Jaccard sera égal à $7/13 = 0.54$. L'indice de Jaccard est donc compris entre 0 et 1, avec 1 indiquant une correspondance parfaite entre les motifs prédits et les motifs réels. Un autre critère utilisé dans la littérature est la valeur prédictive positive (PPV pour "Positive Predictive Value") qui est le pourcentage de motifs prédits qui ont un index de Jaccard avec le vrai motif d'au moins 0.5. Ces deux derniers critères seront utilisés pour évaluer vos prédictions lors de la compétition (voir plus bas).

Questions suggérées. Les questions suivantes, entre autres, pourraient être abordées par le biais de vos expériences :

- Obtenez-vous les mêmes résultats quand vous relancez l'algorithme ?
- Quel impact ont les paramètres de l'algorithme (nombre d'itérations, gestion du décalage, degré du modèle de séquence hors motif, paramètres des distributions *a priori*, etc.) sur ses performances ?
- Quel est l'impact des paramètres du problème (nombre et longueur des séquences de S , longueur du motif) sur les performances ?
- Quel est l'effet du choix du modèle hors motif (multinomiale ou chaîne de Markov) ?
- Que se passe-t-il si la longueur W utilisée par l'algorithme ne correspond pas à la longueur du vrai motif ? Pouvez-vous trouver une stratégie pour déterminer la longueur du motif dans le cas où elle serait inconnue ?

5. Voir https://en.wikipedia.org/wiki/Sequence_logo et <https://logomaker.readthedocs.io/en/latest/>.

2.2.4 Compétition

Quelques jours avant la date de remise du projet, deux ensembles de séquences vous seront fournis et vous devrez appliquer l'algorithme que vous aurez développé sur ces séquences pour obtenir la meilleure estimation possible des positions du motif et de sa matrice de paramètres. Vous devrez soumettre vos prédictions sur Gradescope et celles-ci seront comparées à celles des autres groupes sur base des critères AJI et PPV. Le format du fichier de séquences sera le même que pour les séquences fournies sur Ecampus.

3 Soumission

Vous devez nous fournir un rapport au format pdf contenant vos réponses, concises mais précises, aux questions posées ainsi que le code que vous avez utilisés pour y répondre. Le tout est à soumettre sur Gradescope.

A la fin du rapport, expliquez dans une section séparée la contribution de chacun des membres du groupe au travail. La soumission du rapport suppose que chaque membre du groupe accepte la responsabilité de l'entièreté du contenu du rapport et du code.

Pour vos expériences, nous vous encourageons à utiliser le Python mais vous pouvez utiliser un autre langage de programmation si vous le souhaitez (avec notre accord, si ce n'est pas C/C++, Java, Mathematica, ou R).

Plagiat et utilisation de l'IA. Quel que soit le langage choisi, on vous demande d'implémenter les fonctions nécessaires pour répondre aux questions de l'énoncé par vous-mêmes. Vous ne pouvez pas utiliser une boîte à outils existante qui ferait partiellement ou totalement ce qui vous est demandé. De même, l'utilisation d'outils d'IA générative est interdite pour générer le code demandé ou pour générer directement les réponses aux questions posées dans l'énoncé. Vous pouvez cependant l'utiliser pour vous renseigner sur le sujet du projet, pour générer du code annexe non lié à la matière, par exemple pour générer des graphiques de résultats, ou pour des corrections grammaticales ou d'orthographe dans votre rapport, en respectant la charte d'utilisation des outils d'intelligence artificielle de la faculté⁶. Précisez bien toute utilisation d'IA et toutes les sources consultées à la fin de votre rapport. En soumettant votre projet, vous confirmez avoir respecté ces règles. En cas de doute sur l'origine d'un code ou texte remis, vous serez convoqués pour obtenir des explications et le cas échéant, des sanctions seront prises.

4 Références

Toutes les références, les données, et les codes relatifs au projet seront disponibles sur Ecampus. Des conseils et réponses aux questions fréquentes seront également rassemblées sur cette page au fur et à mesure. Un forum de discussion a également été ouvert. Veuillez à consulter régulièrement Ecampus tout au long du projet.

6. Disponible ici : https://www.fsa.uliege.be/upload/docs/application/pdf/2023-11/chatgpt_student.pdf.

Références

- [1] S. Castellana, T. Biagini, L. Parca, F. Petrizzelli, S. D. Bianco, A. L. Vescovi, M. Carella, and T. Mazza. A comparative benchmark of classic DNA motif discovery tools on synthetic data. *Briefings in Bioinformatics*, 22(6), 08 2021.
- [2] C. E. Lawrence, S. F. Altschul, M. S. Boguski, J. S. Liu, A. F. Neuwald, and J. C. Wootton. Detecting subtle sequence signals : a gibbs sampling strategy for multiple alignment. *Science*, 262(5131) :208–214, Oct. 1993.
- [3] J. S. Liu. The collapsed gibbs sampler in bayesian computations with applications to a gene regulation problem. *Journal of the American Statistical Association*, 89(427) :958–966, Sept. 1994.
- [4] G. Thijs, M. Lescot, K. Marchal, S. Rombauts, B. De Moor, P. Rouzé, and Y. Moreau. A higher-order background model improves the detection of promoter regulatory elements by gibbs sampling. *Bioinformatics*, 17(12) :1113–1122, 12 2001.
- [5] G. Thijs, K. Marchal, M. Lescot, S. Rombauts, B. De Moor, P. Rouzé, and Y. Moreau. A gibbs sampling method to detect over-represented motifs in the upstream regions of co-expressed genes. In *Proceedings of the Fifth Annual International Conference on Computational Biology*, RECOMB '01, page 305–312, New York, NY, USA, 2001. Association for Computing Machinery.